Điểm danh bằng giọng nói trên ESP32-S3

So sánh supervised và knowledge distillation

Trần Tú Quang 250201084 · **Tô Huỳnh Minh Tiến** 250201095 · **Nguyễn Ấn** 250201042

GVHD: TS. Nguyễn Tất Bảo Thiện

IT2058 · Báo cáo nghiên cứu và demo hệ thống

University of Information Technology, VNU-HCM (UIT) · TP.HCM, 10/2026

Bối cảnh và bài toán



- **Bối cảnh:** điểm danh bằng giọng nói trong danh sách đã đăng ký.
- **Đầu vào:** PCM16 mono 16 kHz, **3 giây** và mẫu đăng ký gồm nhãn + vector.
- **Đầu ra:** tên có cosine cao nhất cùng điểm của từng người.
- **Phạm vi:** chưa từ chối người lạ; cosine là độ tương đồng.

Mục tiêu và câu hỏi nghiên cứu



1. **Chất lượng mô hình:** KD thay đổi EER và Top-1 thế nào so với supervised, trước và sau INT8?
2. **Chi phí trên board:** giảm được bao nhiêu thời gian và RAM tiền xử lý khi giữ nguyên đầu ra?

Cách đối chiếu: cùng student, dữ liệu và quy trình đánh giá. Đo tiền xử lý trên ESP32-S3 với bản tham chiếu.

Teacher và student

Teacher

SpeechBrain · ECAPA-TDNN

speechbrain/spkrec-ecapa-voxceleb

- Giữ cố định trọng số teacher
- Tạo embedding cho nhánh KD khi huấn luyện
- Không chạy trên ESP32-S3

Student

baseline_conv8 (1 lớp convolution, 8 kênh)

Input: [1, 298, 40, 1]

Conv2D 8 kênh + ReLU
Kernel 3 × 3, stride 2 × 2

↓

Average Pooling
Pool 8 × 4, stride 8 × 4

↓

Flatten: 760 giá trị

↓

Dense 192: embedding [1, 192]

AAM head: **chỉ dùng lúc train**, không lên board.

Teacher tạo embedding cho dữ liệu train. Chỉ student được xuất và nạp lên ESP32-S3.

Huấn luyện với AAM và KD

Supervised AAM

AAM dùng nhãn người nói để cập nhật student.

KD + AAM

Giữ loss AAM, thêm loss cosine giữa embedding student và teacher.

Hàm mất mát AAM (chỉ dùng khi train)

$$L_{\text{AAM}} = -\log \frac{e^{s\cos(\theta_y + m)}}{e^{s\cos(\theta_y + m)} + \sum_{j=1, j\neq y}^{C} e^{s\cos\theta_j}}$$

θ_j: góc giữa embedding và vector lớp j, y: nhãn đúng, C = 251 lớp người nói.

m = 0,2 rad: biên góc, **s = 30**: hệ số nhân logit.

KD: $L = L_{\text{AAM}} + \lambda \cdot [1 - \cos(z_{\text{student}}, z_{\text{teacher}})]$, $\lambda = 1$.

Khi suy luận, bỏ AAM và teacher; chỉ dùng encoder và cosine với mẫu đăng ký.

Dữ liệu và quy trình đánh giá

Huấn luyện

LibriSpeech **train-clean-100**

251 người nói · 28.539 bản ghi

Validation · tách người nói khỏi train

5 người · 60 mẫu

Mỗi người: 3 đăng ký + 9 query

Chỉ số	Cách tính trên validation	Mục tiêu
EER	Mức lỗi khi nhận nhầm bằng từ chối nhầm 45 cặp cùng người + 180 cặp khác người	Thấp hơn
Top-1	Số query chọn đúng người / 45 query	Cao hơn

Validation dùng để chọn checkpoint và báo cáo kết quả; chưa có test độc lập.

Full100: kết quả validation

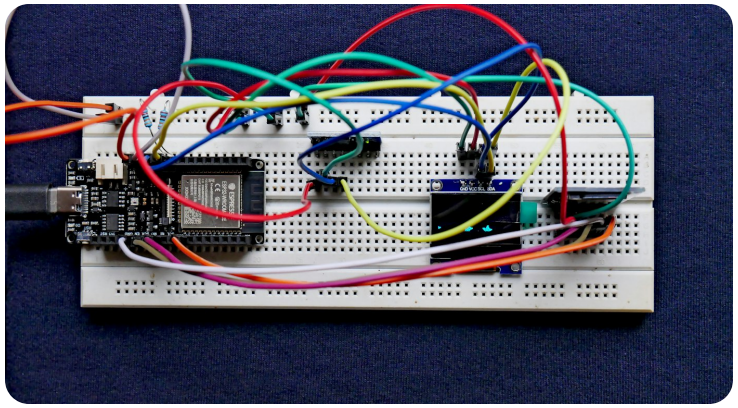
Cách huấn luyện	Encoder	EER	Top-1
Supervised AAM	FP32	**4.4444%**	43/45
Supervised AAM	INT8	**4.4444%**	43/45
KD + AAM	FP32	**2.7778%**	45/45
KD + AAM	INT8	**4.1667%**	45/45

KD + AAM có EER thấp hơn ở FP32. Sau INT8, EER tăng từ **2.7778% lên 4.1667%**, trong khi Top-1 vẫn **45/45** trên validation.

So sánh cùng student và protocol. Nguồn: hai báo cáo FULL100 và audit độc lập.

Phần cứng

Thiết bị đang dùng	Vai trò
ESP32-S3	Tiền xử lý, encoder, cosine và lưu mẫu
Mic của Mac	Thu PCM 3 giây, mono 16 kHz
Native USB	Truyền PCM và kết quả
Dashboard trên Mac	Điều khiển demo, hiển thị số đo



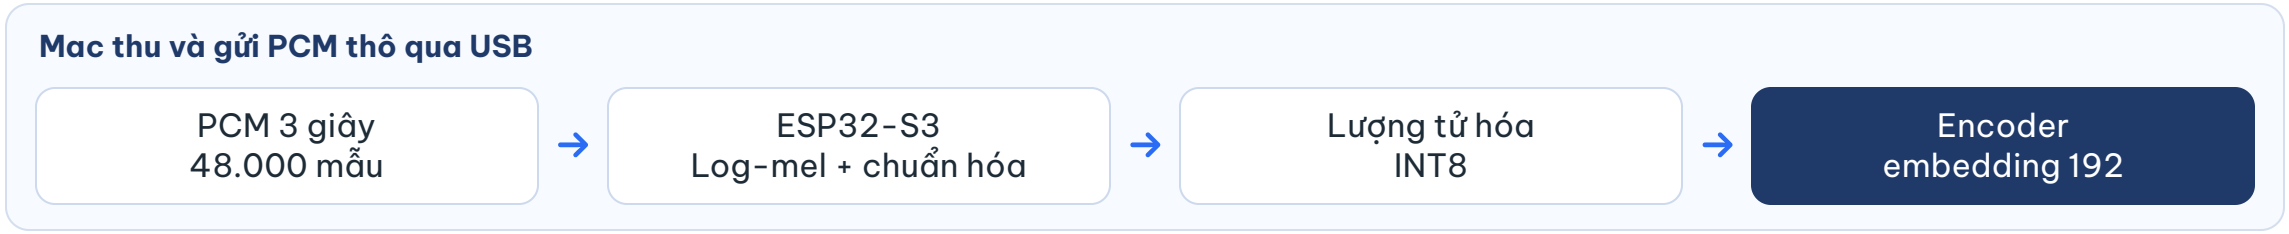
Ảnh minh họa, không phải bộ demo đã lắp.

ESP32-S3: 512 KB SRAM nội bộ, 16 MB Flash, 8 MB PSRAM.

Thực nghiệm dùng SRAM nội bộ, chưa bật PSRAM.

Chưa gắn INMP441. Mic Mac là đầu vào tạm thời; chưa đo điện năng.

Luồng xử lý PCM trên board



Đăng ký · thao tác riêng

Chuẩn hóa embedding → lưu **nhãn + vector** trong NVS.

LS116 và LS700 dùng luồng đăng ký PCM này. NVS không lưu file âm thanh.

Nhận diện · mỗi query

Cosine với mẫu NVS → chọn tên → gửi **tên và điểm** về Mac.

Query chỉ đọc mẫu; dashboard hiển thị kết quả và số đo.

Ứng dụng Mac không tính đặc trưng, embedding hay cosine. Huấn luyện và xuất model thực hiện trước khi demo.

Kích thước model và bộ nhớ

Thành phần	Kích thước	Trong demo
Encoder FP32	587.132 byte	Không nạp
Encoder INT8 · đã nạp	**154.000 byte**	Flash
Tensor arena · dùng / cấp phát	**38.140 / 131.072 byte**	SRAM
NVS · 5 nhãn và vector	**3.972 byte**	Flash

Heap nội bộ khi chờ: **183.192 byte trống / 239.908 byte tổng vùng đo**.

Khi xử lý còn cần buffer PCM, workspace frontend và stack. Arena không phải tổng RAM sử dụng.

Heap là snapshot STATUS, chưa phải RAM đỉnh. Bản ghi NVS chưa tính overhead lưu trữ.

Tối ưu tiền xử lý trên ESP32-S3

Số đo	Trước tối ưu	Sau tối ưu
Frontend · Quang / Tien	7,659 / 7,656 s	**2,854 / 2,851 s**
Nhận diện trên board	7,715 / 7,712 s	**2,909 / 2,907 s**
Gửi PCM đến nhận kết quả qua USB	8,101 / 8,099 s	**3,218 / 3,222 s**
Workspace của frontend	10.568 byte	**8.512 byte**

- Tính sẵn Hann, hệ số FFT và thứ tự đảo bit; chỉ duyệt **494 trọng số mel khác 0**.
- Giữ phép tính double. Trên hai query này, đầu ra encoder PCM trùng đường tensor cũ.

Frontend giảm khoảng 62,7%. Bản tối ưu không có cảnh báo watchdog trong hai lượt đo; chưa đánh giá chạy liên tục.

Hai PCM cố định; riêng encoder ≈53,6 ms. Thời gian USB chưa gồm 3 giây thu âm.

Kết quả demo trên ESP32-S3

Năm mẫu trong NVS: **Quang, Tien, An, LS116, LS700**.

Query	Gửi tới board	Board chọn	Cosine cao nhất
Quang_test	Tensor cũ	**Quang**	0,9130
Tien_test	Tensor cũ	**Tien**	0,7994
LS116 · query 1 / 2	PCM thô	**LS116 / LS116**	0,8450 / 0,8094
LS700 · query 1 / 2	PCM thô	**LS700 / LS700**	0,7734 / 0,7375

Bốn query PCM dùng câu khác mẫu đăng ký, từ LibriSpeech dev-other. Board nhận diện trong danh sách năm người.

Hai tensor cũ bỏ qua frontend. Sáu query cố định chưa đủ kết luận độ chính xác chung hay chất lượng mic trực tiếp.

Nguồn: bản ghi USB sau khởi động lại, 23/10/2026. Điểm đã làm tròn.

Kết luận

Kết quả nghiên cứu

KD + AAM cho kết quả tốt hơn supervised trong phép so sánh hiện tại. INT8 làm EER của nhánh KD tăng dù Top-1 giữ nguyên.

Kết quả triển khai

ESP32-S3 thực hiện toàn bộ xử lý PCM và nhận diện. Tối ưu frontend rút ngắn thời gian, giữ đầu ra trên các mẫu đã kiểm tra.

Phần nhóm thực hiện: đối chiếu cách huấn luyện, kiểm chứng INT8 và đo chi phí triển khai trên board thật.

Giới hạn và bước tiếp theo

Giới hạn hiện tại	Bước kiểm chứng tiếp theo
Validation nhỏ, đã dùng chọn checkpoint	Test độc lập, thêm người nói và lặp lại huấn luyện
Chưa từ chối người ngoài danh sách	Hiệu chỉnh ngưỡng trên tập riêng, đo lỗi chấp nhận / từ chối
Mic Mac, xử lý từng đoạn PCM	Gắn mic I2S, đo chất lượng thu và độ trễ toàn luồng
Các lượt đo ngắn, query cố định	Thử nhiễu, theo dõi RAM và độ ổn định khi chạy liên tục

Tài liệu tham khảo

1. Desplanques et al. **ECAPA-TDNN: Emphasized Channel Attention, Propagation and Aggregation in TDNN Based Speaker Verification.** Interspeech 2020.
2. Nagrani et al. **VoxCeleb: A Large-Scale Speaker Identification Dataset.** Interspeech 2017.
3. Panayotov et al. **Librispeech: An ASR Corpus Based on Public Domain Audio Books.** ICASSP 2015.
4. Hinton et al. **Distilling the Knowledge in a Neural Network.** 2015.
5. Deng et al. **ArcFace: Additive Angular Margin Loss for Deep Face Recognition.** CVPR 2019.
6. Jacob et al. **Quantization and Training of Neural Networks for Efficient Integer-Arithmetic-Only Inference.** CVPR 2018.
7. Ravanelli et al. **SpeechBrain: A General-Purpose Speech Toolkit.** 2021.
8. David et al. **TensorFlow Lite Micro: Embedded Machine Learning for TinyML Systems.** MLSys 2021.
9. Nguyen-Tat, Bui, Ngo. **Automating attendance management in human resources.** IJIM Data Insights, 2024.
10. Nguyen-Tat, Ngo. **Lite-XNet: An efficient deep learning model for COVID-19 lung severity assessment on embedded systems.** CVIU, 2026.

Ảnh minh họa: Unsplash. Dữ liệu demo LS116/LS700: LibriSpeech dev-other, CC BY 4.0.

Cảm ơn Thầy và các bạn đã lắng nghe

Trần Tú Quang · Tô Huỳnh Minh Tiến · Nguyễn Ấn

University of Information Technology, VNU-HCM (UIT)