Điểm danh bằng giọng nói trên ESP32-S3

Đối chiếu supervised và knowledge distillation

Trần Tú Quang 250201084 · **Tô Huỳnh Minh Tiến** 250201095 · **Nguyễn Ấn** 250201042

GVHD: TS. Nguyễn Tất Bảo Thiện

IT2058 · Báo cáo nghiên cứu và demo hệ thống

University of Information Technology, VNU-HCM (UIT) · TP.HCM, 10/2026

Bối cảnh và ý tưởng



- **Hiện nay:** gọi tên từng bạn mất thời gian; ký tên trên giấy lại dễ bị điểm danh hộ.
- **Ý tưởng:** sinh viên nói một câu ngắn, thiết bị nhận ra là ai trong danh sách đã đăng ký
- **Thiết bị:** vi điều khiển ESP32-S3, rẻ hơn nhiều so với Jetson Nano, rẻ hơn cả Raspberry Pi, tốn ít điện
- **Xử lý tại chỗ:** không gửi giọng nói lên server, không cần mạng

Mục tiêu



1. **Nhận diện người nói trên chip:** encoder và so khớp cosine chạy trên ESP32-S3 với đoạn nói 3 giây
2. **Model đủ nhỏ để nạp vào chip mà vẫn nhận đúng:** so supervised và KD trên cùng student, chọn cách nhận đúng hơn
3. **Đo tác động của nén INT8:** so EER và top-1 trước và sau khi nén

Khó khăn chính: model nhận giọng tốt hiện nay (ECAPA-TDNN) nặng khoảng 80MB, trong khi chip chỉ có 512KB SRAM. Encoder INT8 của nhóm còn **154.000 byte**, nhỏ hơn vài trăm lần.

Model lớn và model nhỏ

Teacher · ECAPA-TDNN
SpeechBrain · frozen CPU
speechbrain/
spkrec-ecapa-voxceleb



dấu vân giọng của model lớn

↕ khớp embedding

Student encoder
baseline_conv8
embedding 192



dấu vân giọng của model nhỏ

KD + AAM-softmax
student nhận hướng dẫn từ teacher qua embedding

AAM-softmax supervised
nhánh supervised độc lập: học theo nhãn speaker, không dùng teacher

Embedding: 192 số tóm tắt đặc điểm giọng · AAM head chỉ dùng lúc train; encoder xuất riêng.

- **Đích triển khai:** ESP32-S3; encoder chạy trên board khoảng **53,5 ms/mẫu**
- **INT8:** baseline_conv8 **154.000 byte** (FP32 587.132 byte)

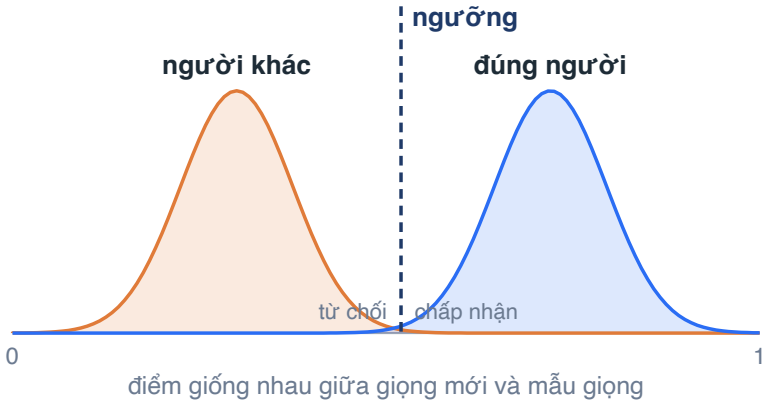
Xử lý trên thiết bị



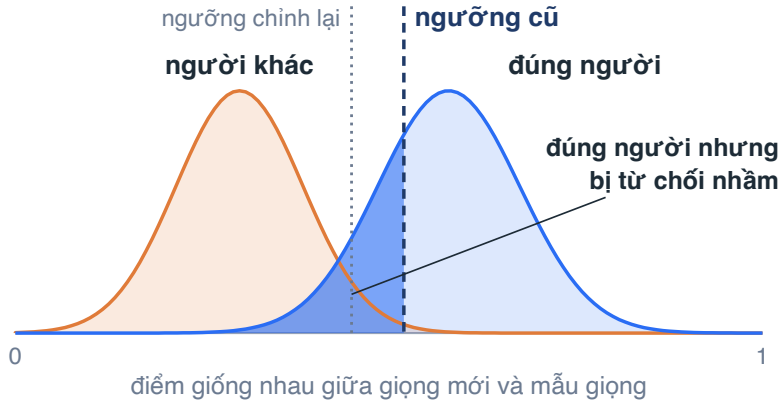
- **Đủ giống:** điểm giống nhau vượt **ngưỡng**
- **Tránh nhầm người:** nếu hai bạn có điểm gần nhau, thiết bị mời nói lại. Sau hai lần chưa rõ, giảng viên nhập MSSV để kiểm tra riêng

Ngưỡng là gì, vì sao có thể lệch

Trên máy tính: ngưỡng chọn vừa khít



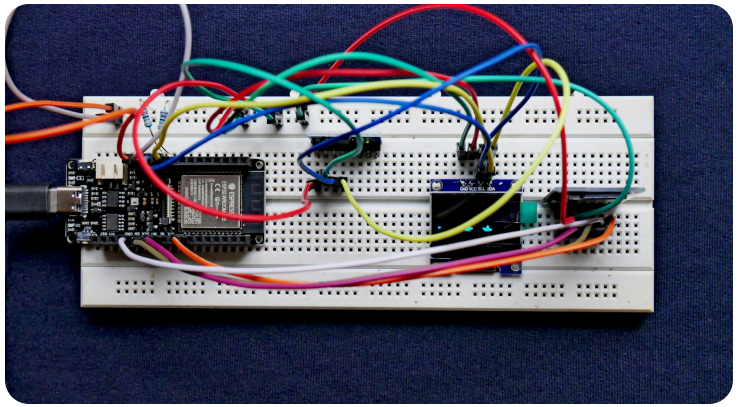
Sau khi nén, hoặc trong lớp thật



- **Ngưỡng:** điểm giống nhau từ mức này trở lên thì nhận là đúng người. Chọn sao cho gần như không nhận nhầm người khác (≤ 1%)
- **Vì sao lệch:** nén model, micro rẻ và phòng học thật đều làm điểm số xê dịch. Giữ ngưỡng cũ thì nhiều bạn bị từ chối nhầm hơn
- **Nhóm sẽ đo:** lệch bao nhiêu, và chỉnh lại ngưỡng bằng chính giọng đã đăng ký của lớp có khắc phục được không

Phần cứng

Linh kiện	Vai trò
ESP32-S3	Thiết bị chính (512 KB SRAM)
INMP441	Micro thu âm
OLED 0,96"	Màn hình hiện tên
Nút, buzzer	Bắt đầu lượt nói, báo kết quả
INA219	Đo điện năng tiêu thụ



So sánh	Jetson Nano (bài mẫu)	Raspberry Pi	ESP32-S3 (đồ án)
Loại thiết bị	Máy tính nhúng có GPU	Máy tính nhúng	Vi điều khiển
Chi phí	Cao	Trung bình	**Thấp nhất**
Điện năng	Cao	Trung bình	**Thấp, chạy pin được**

Kiến trúc phần mềm

Máy tính · huấn luyện

- Tính phổ âm thanh (bản chuẩn)
- Chạy model lớn
- Train hai model nhỏ
- Nén INT8, chọn ngưỡng

ESP32-S3 · chương trình chip

- Thu âm, bỏ khoảng lặng
- Tính phổ âm thanh
- Chạy model nhỏ, so với mẫu
- Hiện tên, gửi kết quả

Laptop · sổ điểm danh

- Nhận kết quả từ thiết bị
- Lưu sổ, chặn ghi trùng
- Đăng ký giọng, nhập MSSV
- Xuất file CSV

Máy tính: file model nhỏ → nạp vào chip ESP32-S3 → kết quả điểm danh → laptop

Phát biểu bài toán

Cho một đoạn giọng nói và các mẫu đăng ký, xác định người nói phù hợp nhất.

Đầu vào

- Audio query **3 giây**, chuẩn hóa về mono **16 kHz**
- Mẫu đã đăng ký: **nhãn + vector 192 chiều** cho mỗi người

Đầu ra

- **Tên người có cosine cao nhất** trong các mẫu đăng ký
- **Điểm cosine với từng mẫu**, thể hiện độ tương đồng

I/O của encoder: tensor INT8 [1, 298, 40, 1], đầu ra embedding INT8 [1, 192].
Phân chia xử lý: Mac thu âm và làm frontend. ESP32-S3 chạy encoder và cosine.

Demo closed-set với Quang, Tien, An. Chưa có ngưỡng từ chối người lạ. Cosine không phải xác suất.

Câu hỏi nghiên cứu

> **Câu hỏi:** Với cùng kiến trúc student và dữ liệu huấn luyện, KD ảnh hưởng thế nào đến chất lượng speaker verification sau INT8 so với supervised?

Các bản so sánh

- Cùng baseline_conv8, cùng embedding 192 chiều
- So sánh supervised AAM với KD + AAM
- Đo cùng hai trạng thái FP32 và INT8

Full100 đánh giá trên validation. Demo board gồm nhận diện closed-set và đăng ký thêm mẫu.

Thiết kế thực nghiệm

Supervised AAM

Student học nhãn người nói bằng AAM.
Xuất encoder riêng ở FP32 và INT8.

KD + AAM

Student học nhãn và khớp embedding teacher.
Teacher chạy offline, không lên board.

Hàm mất mát AAM (chỉ dùng khi train)

$$L_{\mathrm{AAM}} = -\log \frac{e^{s\cos(\theta_y + m)}}{e^{s\cos(\theta_y + m)} + \sum_{j=1, j\neq y}^{C} e^{s\cos\theta_j}}$$

θ_j: góc giữa embedding và vector lớp j, y: nhãn đúng, C = 251 lớp người nói.

m = 0,2 rad: biên góc, **s = 30**: hệ số nhân logit.

Biến so sánh

Supervised so với KD
FP32 so với INT8

Giữ cố định

baseline_conv8, embedding 192 chiều
Dữ liệu, frontend và validation protocol

Nguồn: full_training_report.json của hai run và src/edgeai/comparative_training.py.

Dữ liệu và cách chia

Huấn luyện

- LibriSpeech train-clean-100
- **251 người nói**
- **28.539 bản ghi**

Đánh giá (validation)

- **5 người nói**, **60 mẫu**
- Mỗi người: **3 đăng ký + 9 kiểm tra**
- Tổng cộng **45 mẫu kiểm tra**

Hai tập không trùng người nói.

Kết quả hiện tại chỉ trên validation, chưa có test độc lập.

Teacher và student

Teacher

SpeechBrain · ECAPA-TDNN
speechbrain/spkrec-ecapa-voxceleb

- Snapshot frozen, chạy offline
- Chỉ cung cấp teacher embedding cho KD
- Không chạy trên ESP32-S3

Student

baseline_conv8 (1 lớp convolution, 8 kênh)

Input: [1, 298, 40, 1]

Conv2D 8 kênh + ReLU
Kernel 3 × 3, stride 2 × 2

↓

Average Pooling
Pool 8 × 4, stride 8 × 4

↓

Flatten: 760 giá trị

↓

Dense 192: embedding [1, 192]

AAM head: **chỉ dùng lúc train**, không lên board.

Teacher snapshot là nguồn hướng dẫn offline, không phải dữ liệu student độc lập và không được nạp lên board.

Quantization và export

Thành phần	Giá trị artifact
Encoder FP32	587.132 byte
Encoder INT8	**154.000 byte**
Input tensor	INT8, **11.920 byte**
Output tensor	INT8, 192 giá trị

Nguồn: full_ training_ report.json của hai run và board report ngày 19/10/2026. Byte dùng đơn vị decimal.

Sơ đồ thử nghiệm

Đăng ký mẫu

Mac audio + frontend → quant INT8 11.920 B → **USB ESP32-S3** → baseline_conv8 encoder only → NVS mẫu đã đăng ký

Query và hiển thị

Mac audio + frontend → quant INT8 11.920 B → **ESP32-S3 encoder 192** → cosine + đọc mẫu NVS top1 closed-set · không ghi → Mac display

Board không có microphone. Đăng ký ghi mẫu vào NVS, query chỉ đọc để so cosine.

5 người nói

Mỗi người: **3 mẫu đăng ký + 9 mẫu kiểm tra**

EER

Lỗi nhận nhầm và từ chối nhầm

45 cặp cùng người + 180 cặp khác người

Càng thấp càng tốt

Top-1

Tỷ lệ chọn đúng người trong 5 người

Số mẫu đúng / 45 mẫu kiểm tra

Càng cao càng tốt

Chỉ báo cáo kết quả trên tập validation.

Full100: kết quả validation

Mục tiêu train	Encoder	EER	top1
Supervised AAM	FP32	**4.4444%**	43/45
Supervised AAM	INT8	**4.4444%**	43/45
KD + AAM	FP32	**2.7778%**	45/45
KD + AAM	INT8	**4.1667%**	45/45

Trong bốn cấu hình, **KD + AAM INT8** có EER **4.1667%** và top1 **45/45** trên validation slice. Cả hai INT8 encoder đều có kích thước **154.000 byte**.

Bảng dùng cùng 5 speaker, 3 enrollment và 9 query mỗi speaker. Nguồn: frozen reports + independent final audit.

Kết quả demo trên ESP32-S3

File kiểm tra	Cosine với mẫu đăng ký			Board chọn
	Tien.m4a	Quang.m4a	An.m4a	
Quang_test.m4a	0.6627	**0.9130**	0.4884	**Quang**
Tien_test.m4a	**0.7994**	0.7014	0.4298	**Tien**

Board chọn người có điểm cosine cao nhất.

Encoder: **khoảng 53,5 ms/mẫu**

Tensor arena: **38.140 / 131.072 byte**

Nguồn: đo trực tiếp trên ESP32-S3 (20/10). Điểm cosine đã làm tròn.

Kết luận

Chất lượng: KD + AAM INT8 đạt EER **4.1667%**, Top-1 **45/45** trên validation.

Triển khai: encoder INT8 **154.000 byte** chạy trên ESP32-S3, khoảng **53,5 ms/mẫu**.

Demo: nhận diện đúng hai file Quang/Tien và đăng ký thêm **An** vào NVS.

Kết quả hiện giới hạn ở validation và các mẫu demo đã kiểm tra.

Hướng phát triển tiếp theo

Kiểm thử độc lập

Thu query riêng cho An, thêm người nói và điều kiện thu âm.

Nhận diện người lạ

Hiệu chỉnh ngưỡng cosine trên tập calibration riêng.

Kiểm tra độ ổn định

Đo độ trễ toàn luồng và thử NVS qua nhiều lần tắt/bật.

Tài liệu tham khảo

1. Desplanques et al. **ECAPA-TDNN: Emphasized Channel Attention, Propagation and Aggregation in TDNN Based Speaker Verification.** Interspeech 2020.
2. Nagrani et al. **VoxCeleb: A Large-Scale Speaker Identification Dataset.** Interspeech 2017.
3. Panayotov et al. **Librispeech: An ASR Corpus Based on Public Domain Audio Books.** ICASSP 2015.
4. Hinton et al. **Distilling the Knowledge in a Neural Network.** 2015.
5. Deng et al. **ArcFace: Additive Angular Margin Loss for Deep Face Recognition.** CVPR 2019.
6. Jacob et al. **Quantization and Training of Neural Networks for Efficient Integer-Arithmetic-Only Inference.** CVPR 2018.
7. Ravanelli et al. **SpeechBrain: A General-Purpose Speech Toolkit.** 2021.
8. David et al. **TensorFlow Lite Micro: Embedded Machine Learning for TinyML Systems.** MLSys 2021.
9. Nguyen-Tat, Bui, Ngo. **Automating attendance management in human resources.** IJIM Data Insights, 2024.
10. Nguyen-Tat, Ngo. **Lite-XNet: An efficient deep learning model for COVID-19 lung severity assessment on embedded systems.** CVIU, 2026.

Một số ảnh minh hoạ lấy từ Unsplash.

Cảm ơn Thầy và các bạn đã lắng nghe

Trần Tú Quang · Tô Huỳnh Minh Tiến · Nguyễn Ấn

University of Information Technology, VNU-HCM (UIT)